## **IRMAR**

#### December 22, 2017

# 1 Présentation et illustration de l'écosystème Python pour la data science

```
Francis Wolinski
@fran6wol
Yotta Conseil - Paris 1
```

### 1.1 Journée Python et Data Science

#### **IRMAR**

Rennes - 19 décembre 2017

## 1.2 Présentation du langage Python

- Programmation par objets permettant un style de programmation fonctionnelle
- Syntaxe élégante et concise
- Large bibliothèque de modules et d'extensions
- Interprété et disposant d'un mode de programmation interactive
- Portable sur Linux, Mac OS X et Windows...
- Open source et supporté par la Python Software Foundation

### 1.3 Les 3 étapes du langage Python

- Les années 1990 : Python 1
  - Langage de script
  - Une alternative à bash
- Les années 2000 : Python 2
  - Calcul scientifique
  - Une alternative à MATLAB
- Les années 2010 : Python 3
  - Data science
  - Une alternative à R

Source : Jake VanderPlas (University of Washington)

# 2 Le succès actuel de Python

Python has continued its upward trajectory from last year and jumped two places to the No. 1 slot, though the top four—Python, C, Java, and C++—all remain very close in popularity.

Source IEEE: https://spectrum.ieee.org/computing/software/the-2017-top-programming-languages

#### 2.1 Python: un langage universel

### 2.2 Python et la data science

Python, whose usage has been growing faster than R for the last several years, has finally caught up with R, and (barely) overtook it, with 52.6% respondents using it v. 52.1% for R.

Source: KDNuggets 2017 Poll http://www.kdnuggets.com/2017/05/poll-analytics-data-science-machine-learning-software-leaders.html

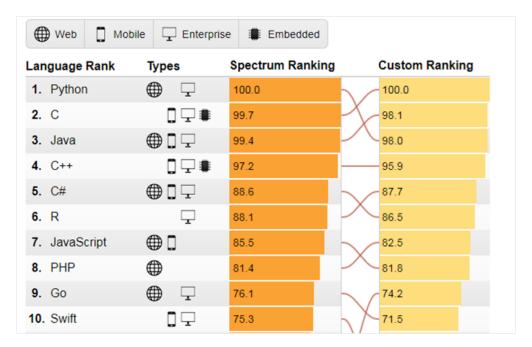


image2.png



image1.png

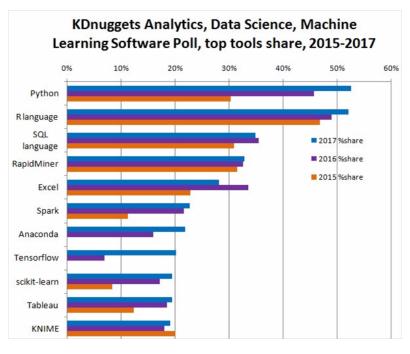


image3.png

is

Python

Growing

So

Quickly

Why

# 3 Ecosystème Python pour la Data Science

Robison

# 3.1 Succès des librairies Python

David

```
https://stackoverflow.blog/2017/09/14/python-growing-quickly/

In []: # launch spyder

%run C:/Test/Anaconda3/Scripts/spyder-script.py

In [7]: # fonctions de Bessel

from numpy import linspace, pi
from scipy.special import jn
from matplotlib.pylab import plot

%matplotlib inline

x = linspace(0, 4*pi)
for i in range(5,-1,-1):
    plot(x, jn(i, x))
```

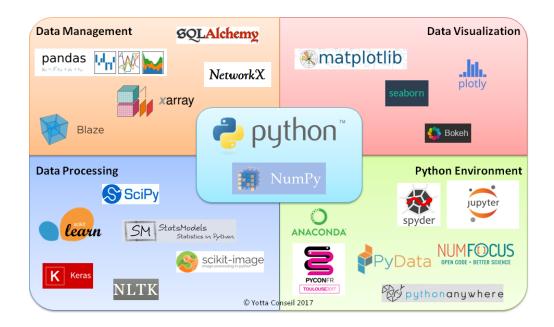


image5.png

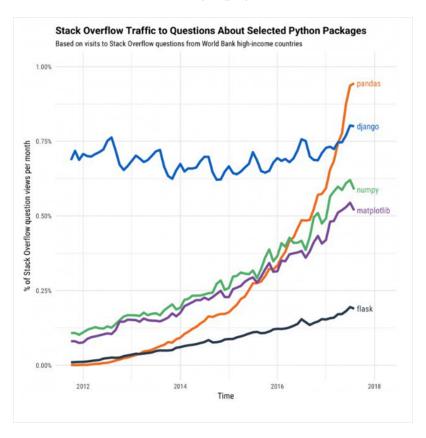
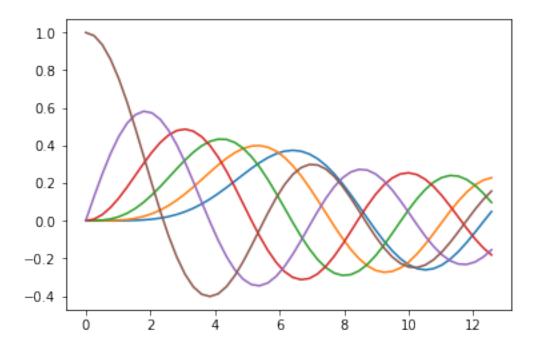


image6.png



$$J_{\nu}(x) = \sum_{n=0}^{\infty} \frac{(-1)^n}{n! \cdot \Gamma(n+1+\nu)} \left(\frac{x}{2}\right)^{2n+\nu}$$

# 4 La révolution Jupyter

# 4.1 NumPy

Librairie destinée à manipuler des matrices ou tableaux multidimensionnels ainsi que des fonctions mathématiques opérant sur ces tableaux

**Caractéristiques principales** - Structure de données ndarray (N-dimentional array) typée dtype (data-type) - Calculs vectoriel et matriciel - Algèbre linéaire, nombres aléatoires, transformations de Fourier... - Outils pour intégrer du C++ et du Fortran

NumPy est optimisé par rapport à Python : ~ x100 pour des boucles numériques

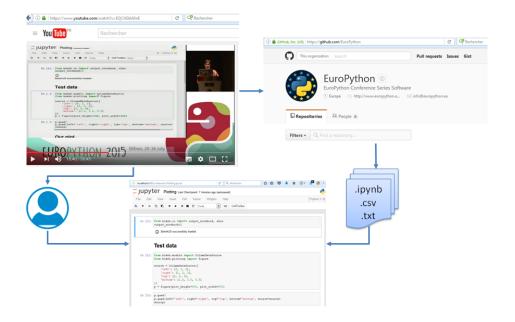


image7.png

## 4.2 Matplotlib

Librairie destinée à tracer et visualiser des données sous formes de graphiques 2D Caractéristiques principales

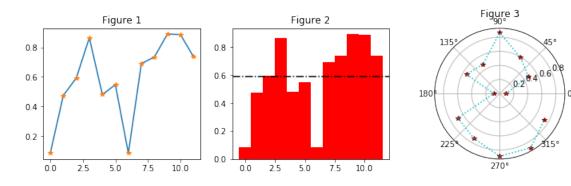
- Graphes de fonctions
- Histogrammes
- Diagrammes de densité
- Graphiques en barres et secteurs
- Nuages de points

#### Nouvelles librairies

- seaborn: statistical data visualization
- bokeh: statistical and novel interactive HTML plots for Python

```
In [11]: import matplotlib.pyplot as plt
    x = np.random.random(12)
```

```
fig = plt.figure(figsize=(12, 3))
ax1 = fig.add_subplot(131)
ax1.set_title("Figure 1")
ax1.plot(x)
ax1.plot(x, '*')
ax2 = fig.add_subplot(132)
ax2.set_title("Figure 2")
ax2.bar(np.arange(12), x, 1, color='r')
ax2.axhline(x.mean(), color='k', linestyle='-.')
ax3 = fig.add_subplot(133, projection='polar')
ax3.set_title("Figure 3")
r = np.linspace(0, (2 - 1 / 6) * np.pi, 12)
ax3.plot(r, x, '*', color='darkred')
ax3.plot(r, x, 'c:');
```

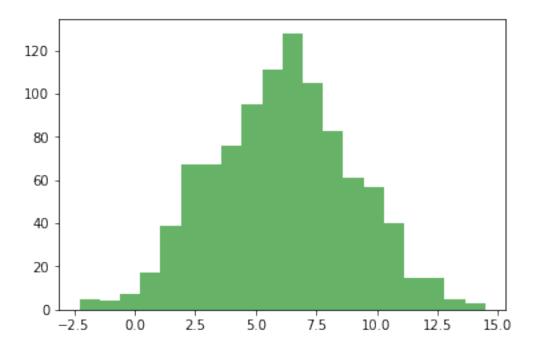


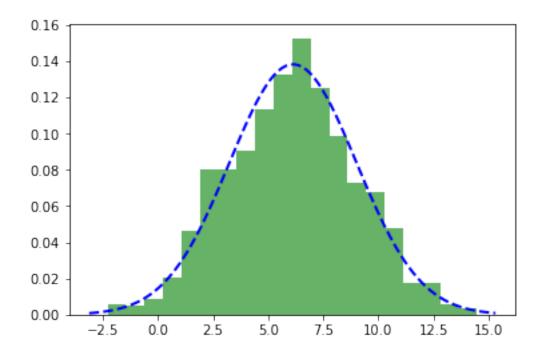
### 4.3 SciPy

Librairie visant à unifier et fédérer un ensemble de librairies Python à usage scientifique

**Caractéristiques principales** - Statistiques - Lois discrètes ou continues - Statistiques descriptives - Tests statistiques - Optimisation - Algèbre linéaire - Matrices creuses - Traitement du signal et d'images

```
In [12]: # random normal distribution
    mu = np.random.randint(10)
    std = np.random.randint(1, 4)
    print("mu={:.2f}, std={:.2f}".format(mu, std))
    a = np.random.normal(mu, std, 1000)
    plt.hist(a, bins=20, color='g', alpha=0.6);
mu=6.00, std=3.00
```





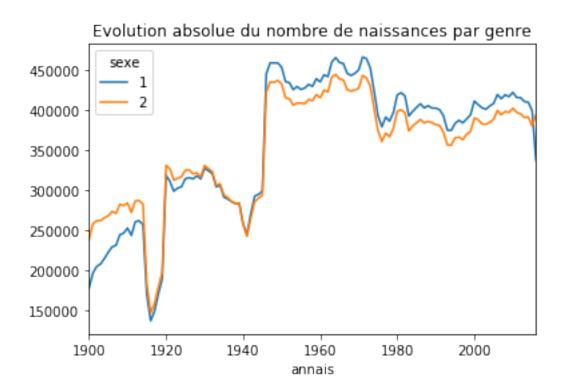
#### 4.4 Pandas

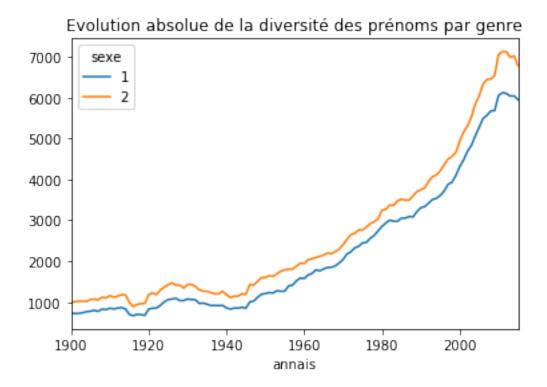
Librairie fournissant des structures de données et les outils d'analyse associés performants et faciles à utiliser

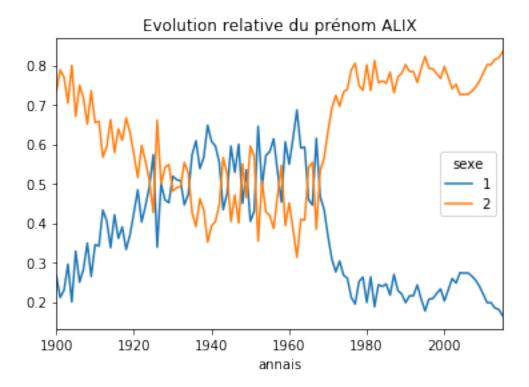
### Caractéristiques principales

- Structure 1D : Series
- Structure 2D: DataFrame
- Intégrée avec NumPy, SciPy et matplotlib...

```
In [14]: import pandas as pnd
          df = pnd.read_csv("c:/Test/mydata/irmar/nat2015.txt",
                              sep="\t",
                              encoding='latin-1')
          df.head(10)
Out [14]:
             sexe preusuel annais
                                      nombre
          0
                1
                               1980
                                         3.0
                          Α
          1
                1
                               1998
                                         3.0
                          Α
          2
                1
                                        21.0
                          Α
                               XXXX
          3
                               1976
                1
                                         5.0
                      AADEL
          4
                1
                      AADEL
                               1978
                                         3.0
          5
                1
                               1980
                                         3.0
                      AADEL
          6
                               1981
                                         5.0
                1
                      AADEL
          7
                1
                      AADEL
                               1982
                                         4.0
          8
                1
                      AADEL
                               1983
                                         3.0
          9
                1
                      AADEL
                               1987
                                         5.0
```







#### 4.5 scikit-learn

Librairie de machine learning et de data mining

### Caractéristiques principales

- Classification (SVM, plus proches voisins, random forest...)
- Régression (linéaire, logistique...)
- Clustering (partitionnement en k-means, ...)
- Réduction de dimension (analyse en composantes principales, ...)
- Sélection de modèle (validations croisées...)
- Intégrée avec NumPy, SciPy et matplotlib
- Keras (réseaux de neurones) fournit une API à la scikit-learn

In [20]: from sklearn.model\_selection import train\_test\_split

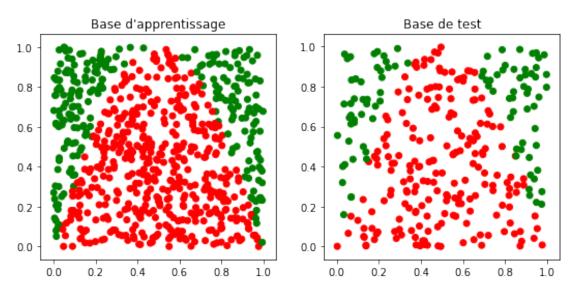
```
X = np.random.random((2, 1000))
y = X[1] > np.sin(np.pi * X[0])
X_train, X_test, y_train, y_test = train_test_split(X.T, y, test_size=0.3)

c_train = np.where(y_train, ['g'] * len(y_train), ['r'] * len(y_train))

c_test = np.where(y_test, ['g'] * len(y_test), ['r'] * len(y_test))

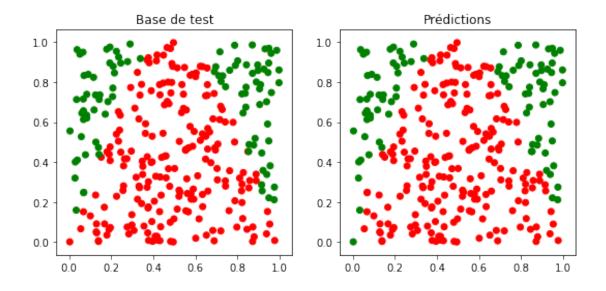
fig = plt.figure(figsize=(9, 4))
ax1 = fig.add_subplot(121)
```

```
ax1.set_title("Base d'apprentissage")
ax1.scatter(X_train.T[0], X_train.T[1], color=c_train)
ax2 = fig.add_subplot(122)
ax2.set_title("Base de test")
ax2.scatter(X_test.T[0], X_test.T[1], color=c_test);
```



```
In [21]: from sklearn.linear_model import LogisticRegression
         from sklearn.svm import SVC
         from sklearn.neural_network import MLPClassifier
         from sklearn.tree import DecisionTreeClassifier
         from sklearn.ensemble import RandomForestClassifier
         from sklearn.metrics import accuracy_score
In [23]: algo = RandomForestClassifier()
         algo.fit(X_train, y_train)
         y_pred = algo.predict(X_test)
         c_pred = np.where(y_pred, ['g'] * len(y_pred), ['r'] * len(y_pred))
         acc_test = accuracy_score(y_test, y_pred)
         print("Accuracy: {:.2f}%".format(acc_test))
         fig = plt.figure(figsize=(9, 4))
         ax1 = fig.add_subplot(121)
         ax1.set_title("Base de test")
         ax1.scatter(X_test.T[0], X_test.T[1], color=c_test)
         ax2 = fig.add_subplot(122)
         ax2.set_title("Prédictions")
         ax2.scatter(X_test.T[0], X_test.T[1], color=c_pred);
```

Accuracy: 0.98%



#### 4.6 Conclusion et Références

- Travis Oliphant Guide to NumPy (2015)
- Jake VanderPlas Python Data Science Handbook (2016)
- Wes McKinney Python for Data Analysis: Data Wrangling with Pandas, Numpy, and IPython (2017)
- Python https://www.python.org/
- SciPy https://www.scipy.org/
- NumPy http://www.numpy.org/
- Pandas http://pandas.pydata.org/
- Matplotlib https://matplotlib.org/
- Scikit Learn http://scikit-learn.org
- Jupyter http://jupyter.org/
- Anaconda https://www.anaconda.com/
- NumFocus https://www.numfocus.org/

In [ ]: